

PROYEK MINI SAINS DATA

**REGRESI LINIER DAN REGRESI PARABOLIK PADA DATA
PENYAKIT KARDIOVASKULAR**



Disusun Oleh:

Nayshila Nesvy.S : 2510514003

Nindira Adiarty : 2510514006

S1 Sains Data

Fakultas Ilmu Komputer

**Jl. RS. Fatmawati No. 1, Pondok Labu, Kecamatan Cilandak, Jakarta Selatan,
DKI Jakarta 12450**

DAFTAR ISI

DAFTAR ISI.....	2
BAB I - PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Tujuan.....	3
BAB II – EKSPLORASI DATA DAN VISUALISASI.....	4
2.1 Dataset.....	4
2.2 Statistik Deskriptif.....	5
BAB III – PEMILIHAN DAN JUSTIFIKASI MODEL.....	8
3.1 Regresi Linier.....	8
3.2 Regresi Parabolik.....	9
3.3 Justifikasi Pemilihan Model.....	10
BAB IV – PERHITUNGAN MANUAL.....	11
4.1 Tabel Regresi Linier.....	12
4.2 Persamaan Normal.....	13
4.3 Tabel Regresi Parabolik.....	13
4.4 Persamaan Regresi Parabolik.....	14
BAB V – IMPLEMENTASI MATLAB.....	15
5.1 Kode Program MATLAB.....	15
5.2 Output Program.....	18
5.3 Grafik Regresi.....	20
BAB VI – EVALUASI MODEL.....	20
6.1 Hasil Evaluasi.....	20
6.2 Residual Plot.....	21
6.3 Analisis Hasil.....	21
BAB VII – KESIMPULAN.....	22
7.1 Kesimpulan.....	22
7.2 Saran.....	22
DAFTAR PUSTAKA.....	23

BAB I - PENDAHULUAN

1.1 Latar Belakang

Regresi merupakan salah satu metode statistik yang sering digunakan untuk menganalisis hubungan antara variabel bebas (X) dan variabel terikat (Y). Melalui metode ini, pengaruh suatu variabel terhadap variabel lainnya dapat diketahui dan diprediksi.

Pada proyek ini, analisis dilakukan menggunakan regresi linier dan regresi parabolik untuk melihat hubungan antara Body Mass Index (BMI) dengan tekanan darah sistolik (SBP). Data yang digunakan berasal dari Cardiovascular Disease Dataset yang diperoleh melalui Kaggle. Pemilihan kedua variabel tersebut didasarkan pada adanya dugaan bahwa peningkatan BMI dapat berpengaruh terhadap tekanan darah seseorang. Oleh karena itu, diperlukan analisis untuk mengetahui pola hubungan yang terbentuk serta model regresi yang paling sesuai dalam menggambarkan hubungan tersebut.

1.2 Tujuan

1. Menganalisis hubungan antara BMI dan tekanan darah sistolik (SBP).
2. Membentuk model regresi linier dan regresi parabolik.
3. Membandingkan kinerja model menggunakan R^2 dan RMSE.
4. Menentukan model terbaik.

BAB II – EKSPLORASI DATA DAN VISUALISASI

2.1 Dataset

Sumber Dataset: Cardiovascular Disease Dataset (Kaggle)

Link Dataset: <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>

Jumlah data sebelum cleaning: 70.000

Jumlah data sesudah cleaning: 69.731

Variabel: BMI (X) dan SBP/ap_hi (Y)

Dataset yang digunakan dalam penelitian ini adalah **Cardiovascular Disease Dataset** yang diperoleh dari Kaggle. Dataset ini berisi informasi kesehatan pasien yang berkaitan dengan faktor-faktor risiko penyakit kardiovaskular, seperti usia, jenis kelamin, tinggi badan, berat badan, tekanan darah, kadar kolesterol, kadar glukosa, kebiasaan merokok, konsumsi alkohol, aktivitas fisik, dan status penyakit kardiovaskular.

Berdasarkan output MATLAB, dataset awal terdiri dari **70.000 data pasien**. Setelah dilakukan proses pembersihan data (data cleaning), jumlah data yang digunakan dalam analisis menjadi **69.731 data**, sehingga terdapat **269 data yang dihapus** karena memiliki nilai BMI atau tekanan darah sistolik yang berada di luar rentang yang ditentukan.

Pada penelitian ini digunakan dua variabel utama, yaitu:

- BMI (Body Mass Index)** sebagai variabel independen (X).
- SBP (Systolic Blood Pressure) atau ap_hi** sebagai variabel dependen (Y).


Nilai BMI dihitung dari data berat badan dan tinggi badan menggunakan rumus:

$$\text{BMI} = \frac{\text{Berat Badan (kg)}}{\text{Tinggi Badan (m)}^2}$$


Berdasarkan hasil statistik deskriptif setelah proses cleaning, nilai BMI memiliki rata-rata sebesar **27,50 kg/m²** dengan nilai minimum **10,73 kg/m²** dan maksimum **70,00 kg/m²**. Sementara itu, tekanan darah sistolik (SBP) memiliki rata-rata sebesar **127 mmHg**, nilai minimum **60 mmHg**, dan maksimum **240 mmHg**.

Data cleaning dilakukan dengan mempertahankan data BMI pada rentang **10–70 kg/m²** dan tekanan darah sistolik pada rentang **50–250 mmHg** agar data yang digunakan lebih valid dan representatif untuk proses pemodelan regresi.

2.2 Statistik Deskriptif




Boxplot BMI sebelum dilakukan proses cleaning menunjukkan bahwa data awal masih memiliki cukup banyak outlier atau nilai yang berada jauh dari mayoritas data. Terlihat beberapa nilai BMI mencapai hampir 300 kg/m², yang jika dilihat dari sisi medis termasuk tidak realistis untuk kondisi manusia normal. Kondisi ini dapat terjadi karena adanya kesalahan input, kesalahan pengukuran, atau data yang memang tidak valid. Sebagian besar data sebenarnya berada pada rentang sekitar 20–30 kg/m², tetapi keberadaan nilai ekstrim membuat sebaran data menjadi terlalu lebar dan dapat mempengaruhi hasil analisis maupun proses pemodelan. Oleh karena itu, tahap cleaning diperlukan agar data yang digunakan lebih sesuai untuk analisis selanjutnya.



Setelah dilakukan proses cleaning dengan membatasi rentang BMI pada nilai 10–70 kg/m^2 , distribusi data terlihat lebih wajar dan lebih terpusat. Mayoritas nilai BMI berada pada kisaran 23–30 kg/m^2 dengan posisi median berada di sekitar pusat distribusi data. Walaupun masih terdapat beberapa outlier, jumlahnya sudah jauh berkurang dibandingkan sebelumnya. Hasil ini menunjukkan bahwa proses cleaning berhasil mengurangi data-data yang tidak sesuai sehingga dataset menjadi lebih representatif dan lebih siap digunakan untuk tahap regresi.


2.3 Histogram BMI



Histogram BMI digunakan untuk melihat bagaimana persebaran indeks massa tubuh pada seluruh pasien dalam dataset. Sebagian besar data berada pada kategori BMI normal hingga overweight, sedangkan jumlah data pada BMI yang terlalu rendah maupun terlalu tinggi relatif


lebih sedikit. Dari distribusi ini dapat diketahui bahwa mayoritas pasien berada pada rentang BMI tertentu sehingga membantu memahami karakteristik data sebelum dilakukan pemodelan.

2.4 Histogram SBP



Histogram SBP menunjukkan pola distribusi tekanan darah sistolik pasien. Sebagian besar data terkumpul pada kisaran 100–150 mmHg yang menunjukkan dominasi pasien dengan tekanan darah normal hingga hipertensi ringan. Informasi ini penting karena memberikan gambaran awal mengenai karakteristik variabel target yang nantinya digunakan dalam proses prediksi.

2.5 Scatter Plot BMI terhadap SBP




Scatter plot digunakan untuk melihat pola hubungan awal antara BMI dan tekanan darah sistolik. Dari persebaran titik terlihat adanya kecenderungan bahwa peningkatan BMI diikuti dengan peningkatan tekanan darah sistolik, walaupun hubungan tersebut tidak terlalu kuat karena sebaran data masih cukup luas. Oleh karena itu, diperlukan pendekatan regresi untuk melihat pola hubungan antar variabel secara lebih jelas dan terukur.

BAB III – PEMILIHAN DAN JUSTIFIKASI MODEL

3.1 Regresi Linier


Persamaan umum: $y = a + bx$



Residual plot pada model linier digunakan untuk melihat selisih antara nilai aktual dengan hasil prediksi model. Dari grafik terlihat bahwa residual belum tersebar secara acak di sekitar garis nol dan masih membentuk pola tertentu. Kondisi ini menunjukkan bahwa model linier belum mampu menangkap seluruh pola hubungan antara BMI dan tekanan darah sistolik. Adanya pola yang masih terlihat pada residual mengindikasikan bahwa hubungan antarvariabel kemungkinan tidak sepenuhnya linear.


3.2 Regresi Parabolik

Persamaan umum: $y = a + bx + cx^2$



Pada model parabolik, residual terlihat lebih menyebar di sekitar garis nol dan pola yang terbentuk tidak sejelas pada model linier. Penyebaran error yang lebih merata menunjukkan bahwa model ini mampu menyesuaikan pola data dengan lebih baik. Selain itu, residual yang lebih kecil dan lebih acak mengindikasikan bahwa model parabolik memiliki kemampuan prediksi yang lebih baik untuk menggambarkan hubungan antara BMI dan tekanan darah sistolik.

3.3 Justifikasi Pemilihan Model



Grafik prediksi menunjukkan hasil estimasi tekanan darah sistolik berdasarkan beberapa nilai BMI menggunakan model parabolik. Titik merah menunjukkan hasil prediksi pada nilai BMI tertentu, sedangkan garis hijau menggambarkan bentuk model yang digunakan. Secara umum

terlihat bahwa semakin tinggi BMI, tekanan darah sistolik juga cenderung meningkat, terutama pada rentang BMI rendah hingga menengah. Namun, pada BMI yang sangat tinggi, kenaikan tekanan darah tidak lagi terlalu tajam sehingga pola hubungan yang terbentuk lebih sesuai direpresentasikan menggunakan model parabolik.

BAB IV – PERHITUNGAN MANUAL

Pembersihan data (EDA)

	A	B	C	D
1	DATA BMI DAN TEKANAN DARAH SISTOLIK (SBP)			
2	No	BMI (kg/m²)	SBP (mmHg)	
3	1	21,9671	110,00	
4	2	34,9277	140,00	
5	3	23,5078	130,00	
6	4	28,7105	150,00	
7	5	23,0112	100,00	
8	6	29,3847	120,00	
9	7	37,7297	130,00	
10	8	29,9836	130,00	
11	9	28,4410	110,00	
12	10	25,2826	110,00	
13	11	28,0102	120,00	
14	12	20,0474	120,00	
15	13	22,0386	120,00	
16	14	31,2450	110,00	
17	15	28,9979	130,00	
18	16	37,8583	120,00	
19	17	25,9516	130,00	
20	18	20,8300	110,00	
	◀ ▶	Sheet1_Data	Sheet2_Regresi_Linier	Sheet3_Regresi_Parabol

	A	B	C
69719	69717	41,9132	130,00
69720	69718	24,0741	120,00
69721	69719	21,4903	120,00
69722	69720	23,0469	110,00
69723	69721	33,6728	120,00
69724	69722	25,5102	110,00
69725	69723	28,4799	130,00
69726	69724	21,6041	170,00
69727	69725	23,6614	130,00
69728	69726	29,3848	150,00
69729	69727	26,9274	120,00
69730	69728	50,4727	140,00
69731	69729	31,3536	180,00
69732	69730	27,0993	135,00
69733	69731	24,9135	120,00
69734			
69735	Jumlah Data (n)	69731	

4.1 Tabel Regresi Linier

	A	B	C	D	E
1	TABEL REGRESI LINIER MANUAL — $y = b_0 + b_1 \cdot X$				
2	No	X (BMI)	Y (SBP)	X²	XY
3	1	21,9671	110,00	482,5535	2416,3810
4	2	34,9277	140,00	1219,9442	4889,8780
5	3	23,5078	130,00	552,6167	3056,0140
6	4	28,7105	150,00	824,2928	4306,5750
7	5	23,0112	100,00	529,5153	2301,1200
8	6	29,3847	120,00	863,4606	3526,1640
9	7	37,7297	130,00	1423,5303	4904,8610
10	8	29,9836	130,00	899,0163	3897,8680
11	9	28,4410	110,00	808,8905	3128,5100
12	10	25,2826	110,00	639,2099	2781,0860
13	11	28,0102	120,00	784,5713	3361,2240
14	12	20,0474	120,00	401,8982	2405,6880
15	13	22,0386	120,00	485,6999	2644,6320
16	14	31,2450	110,00	976,2500	3436,9500
17	15	28,9979	130,00	840,8782	3769,7270
18	16	37,8583	120,00	1433,2509	4542,9960
19	17	25,9516	130,00	673,4855	3373,7080
20	18	20,8300	110,00	433,8889	2291,3000
◀ ▶ Sheet1_Data Sheet2_Regresi_Linier Sheet3_Regresi_Parabolik ⊕					

	A	B	C	D	E
69725	69723	28,4799	130,00	811,1047	3702,3870
69726	69724	21,6041	170,00	466,7371	3672,6970
69727	69725	23,6614	130,00	559,8618	3075,9820
69728	69726	29,3848	150,00	863,4665	4407,7200
69729	69727	26,9274	120,00	725,0849	3231,2880
69730	69728	50,4727	140,00	2547,4934	7066,1780
69731	69729	31,3536	180,00	983,0482	5643,6480
69732	69730	27,0993	135,00	734,3721	3658,4055
69733	69731	24,9135	120,00	620,6825	2989,6200
69734	Σ (Sigma)	1917443,4406	8855826,0000	54672972,0933	245196946,8791

4.2 Persamaan Normal

69736	HASIL PERSAMAAN REGRESI LINIER				
69737	n	69731,0000			
69738	ΣX	1917443,4406			
69739	ΣY	8855826,0000			
69740	ΣX^2	54672972,0933			
69741	ΣXY	245196946,8791			
69742	b_1 (slope)	0,8636			
69743	b_0 (intercept)	103,2536			
69744	Persamaan	$y = 00.001 \cdot x + 00.103$			
69745					
		Sheet1_Data	Sheet2_Regresi_Linier	Sheet3_Regresi_Parabolik	+

4.3 Tabel Regresi Parabolik

	A	B	C	D	E	F	G	H
1	TABEL REGRESI PARABOLIK MANUAL — $y = a + b \cdot X + c \cdot X^2$							
2	No	X (BMI)	Y (SBP)	X^2	X^3	X^4	XY	X^2Y
3	1	21,9671	110,00	482,5535	10600,3006	232857,8634	2416,3810	53080,8831
4	2	34,9277	140,00	1219,9442	42609,8460	1488263,9177	4889,8780	170792,1918
5	3	23,5078	130,00	552,6167	12990,8019	305385,1738	3056,0140	71840,1659
6	4	28,7105	150,00	824,2928	23665,8587	679458,6370	4306,5750	123643,9215
7	5	23,0112	100,00	529,5153	12184,7831	280386,4799	2301,1200	52951,5325
8	6	29,3847	120,00	863,4606	25372,5305	745564,1975	3526,1640	103615,2713
9	7	37,7297	130,00	1423,5303	53709,3697	2026438,4071	4904,8610	185058,9341
10	8	29,9836	130,00	899,0163	26955,7442	808230,2519	3897,8680	116872,1150
11	9	28,4410	110,00	808,8905	23005,6542	654303,8103	3128,5100	88977,9529
12	10	25,2826	110,00	639,2099	16160,8873	408589,2486	2781,0860	70313,0849
13	11	28,0102	120,00	784,5713	21975,9991	615552,1311	3361,2240	94148,5565
14	12	20,0474	120,00	401,8982	8057,0149	161522,2007	2405,6880	48227,7896
15	13	22,0386	120,00	485,6999	10704,1456	235904,3831	2644,6320	58283,9868
16	14	31,2450	110,00	976,2500	30502,9320	953064,1113	3436,9500	107387,5028
17	15	28,9979	130,00	840,8782	24383,7021	707076,1547	3769,7270	109314,1666
18	16	37,8583	120,00	1433,2509	54260,4417	2054208,0818	4542,9960	171990,1055
19	17	25,9516	130,00	673,4855	17478,0274	453582,7760	3373,7080	87553,1205
20	18	20,8300	110,00	433,8889	9037,9058	188259,5775	2291,3000	47727,7790

	A	B	C	D	E	F	G	H
69716	69714	36,7380	130,00	1349,6806	49584,5675	1821637,8408	4775,9400	175458,4837
69717	69715	26,4463	120,00	699,4068	18496,7216	489169,8491	3173,5560	83928,8140
69718	69716	28,3447	120,00	803,4220	22772,7561	645486,9392	3401,3640	96410,6422
69719	69717	41,9132	130,00	1756,7163	73629,6031	3086052,2790	5448,7160	228373,1235
69720	69718	24,0741	120,00	579,5623	13952,4405	335892,4489	2888,8920	69547,4749
69721	69719	21,4903	120,00	461,8330	9924,9296	213289,7144	2578,8360	55419,9593
69722	69720	23,0469	110,00	531,1596	12241,5822	282130,5203	2535,1590	58427,5560
69723	69721	33,6728	120,00	1133,8575	38180,1555	1285632,7392	4040,7360	136062,8952
69724	69722	25,5102	110,00	650,7703	16601,2806	423501,9886	2806,1220	71584,7334
69725	69723	28,4799	130,00	811,1047	23100,1809	657890,8409	3702,3870	105443,6115
69726	69724	21,6041	170,00	466,7371	10083,4358	217843,5549	3672,6970	79345,3133
69727	69725	23,6614	130,00	559,8618	13247,1152	313445,2910	3075,9820	72782,0405
69728	69726	29,3848	150,00	863,4665	25372,7896	745574,3466	4407,7200	129519,9707
69729	69727	26,9274	120,00	725,0849	19524,6503	525748,0698	3231,2880	87010,1845
69730	69728	50,4727	140,00	2547,4934	128578,8724	6489722,8538	7066,1780	356649,0823
69731	69729	31,3536	180,00	983,0482	30822,1011	966383,8283	5643,6480	176948,6819
69732	69730	27,0993	135,00	734,3721	19900,9688	539302,3232	3658,4055	99140,2282
69733	69731	24,9135	120,00	620,6825	15463,3730	385246,7438	2989,6200	74481,8979
69734	Σ (Sigma)	1917443,4406	8855826,0000	54672972,0933	1623725989,3076	50494277370,4706	245196946,8791	7043113788,6716

4.4 Persamaan Regresi Parabolik

69736	SIGMA SUMMARY & HASIL REGRESI PARABOLIK						
69737	n	69731,0000					
69738	ΣX	1917443,4406					
69739	ΣY	8855826,0000					
69740	ΣX^2	54672972,0933					
69741	ΣX^3	1623725989,3076					
69742	ΣX^4	50494277370,4706					
69743	ΣXY	245196946,8791					
69744	ΣX^2Y	7043113788,6716					
69745							
69746	KOEFSISIEN REGRESI PARABOLIK						
69747	a (intercept)	82,8668					
69748	b (koef. X)	2,2403					
69749	c (koef. X^2)	-0,0223					
69750	Persamaan	$y = 00,083 + 00,002 \cdot x + (00,000) \cdot x^2$					

BAB V – IMPLEMENTASI MATLAB

5.1 Kode Program MATLAB

```
TUBES MTKSD.m x | tubes_mtksd_01.m x | untitled x | +
/MATLAB Drive/TUBES MTKSD.m

1  %% =====
2  % PROYEK MINI SAINS DATA Pertemuan 12
3  % Tema 3: BMI vs Tekanan Darah Sistolik
4  % Dataset: Cardiovascular Disease (sullivanova - Kaggle)
5  %% =====
6
7  clc; clear; close all;
8
9  %% -----
10 % STEP 1: MUAT DATA
11 %% -----
12 opts = detectImportOptions('cardio_train.csv', 'Delimiter', ';');
13 T = readtable('cardio_train.csv', opts);
14
15 disp('=== Nama Kolom Dataset ===');
16 disp(T.Properties.VariableNames);
17 disp('=== 5 Baris Pertama ===');
18 disp(head(T, 5));
19 fprintf('Jumlah data awal: %d baris\n', height(T));
20
21 %% -----
22 % STEP 2: HITUNG BMI
```

Activate Windows

Go to Settings to activate Windows.

```
TUBES MTKSD.m x | tubes_mtksd_01.m x | untitled x | +
/MATLAB Drive/TUBES MTKSD.m

23 % BMI = weight (kg) / (height (m))^2
24 % height dalam cm -> dibagi 100
25 %% -----
26 height_m = T.height / 100;
27 BMI_raw = T.weight ./ (height_m.^ 2);
28 SBP_raw = T.ap_hi;
29
30 fprintf('\n--- Sebelum Cleaning ---\n');
31 fprintf('BMI | Min: %6.1f | Max: %6.1f | Mean: %6.1f\n', min(BMI_raw), max(BMI_raw), mean(BMI_raw));
32 fprintf('SBP | Min: %6.1f | Max: %6.1f | Mean: %6.1f\n', min(SBP_raw), max(SBP_raw), mean(SBP_raw));
33
34 %% -----
35 % STEP 3: DATA CLEANING
36 % BMI : 10 - 70 kg/m² (rentang valid manusia dewasa)
37 % SBP : 50 - 250 mmHg (di luar rentang = error input)
38 %% -----
39 idx_valid = (BMI_raw >= 10) & (BMI_raw <= 70) & ...
40 (SBP_raw >= 50) & (SBP_raw <= 250);
41
42 BMI = BMI_raw(idx_valid);
43 SBP = SBP_raw(idx_valid);
44
```

Activate Windows

Go to Settings to activate Windows.

```
TUBES MTKSD.m x | tubes_mtksd_01.m x | untitled x | +
/MATLAB Drive/TUBES MTKSD.m

45 fprintf('\n--- Sesudah Cleaning ---\n');
46 fprintf('Data valid : %d baris\n', length(BMI));
47 fprintf('Data dihapus: %d baris\n', length(BMI_raw) - length(BMI));
48
49 %% -----
50 % STEP 4: STATISTIK DESKRIPTIF
51 %% -----
52 fprintf('\n=== Statistik Deskriptif ===\n');
53 fprintf('%-10s %8s %8s %8s %8s\n', 'Variabel', 'Min', 'Max', 'Mean', 'Median', 'Std');
54 fprintf('%-10s %8.2f %8.2f %8.2f %8.2f %8.2f\n', 'BMI', min(BMI), max(BMI), mean(BMI), median(BMI), std(BMI));
55 fprintf('%-10s %8.2f %8.2f %8.2f %8.2f %8.2f\n', 'SBP', min(SBP), max(SBP), mean(SBP), median(SBP), std(SBP));
56
57 %% -----
58 % STEP 5: VISUALISASI EDA
59 %% -----
60
61 % Figure 1: Histogram BMI
62 figure(1);
63 histogram(BMI, 40, 'FaceColor', '#4472C4', 'EdgeColor', 'white');
64 xlabel('BMI (kg/m²)'); ylabel('Frekuensi');
65 title('Distribusi BMI Pasien');
66 grid on;
```

Activate Windows

Go to Settings to activate Windows.

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
65 title('Distribusi BMI Pasien');
66 grid on;
67
68 % Figure 2: Histogram SBP
69 figure(2);
70 histogram(SBP, 40, 'FaceColor', '#E07D31', 'EdgeColor', 'white');
71 xlabel('Tekanan Darah Sistolik (mmHg)'); ylabel('Frekuensi');
72 title('Distribusi Tekanan Darah Sistolik');
73 grid on;
74
75 % Figure 3: Scatter Plot
76 figure(3);
77 scatter(BMI, SBP, 8, 'filled', 'MarkerFaceColor', '#4472C4', 'MarkerFaceAlpha', 0.15);
78 xlabel('BMI (kg/m²)'); ylabel('Tekanan Darah Sistolik (mmHg)');
79 title('Scatter Plot: BMI vs Tekanan Darah Sistolik');
80 grid on;
81
82 % Figure 4: Boxplot sebelum & sesudah cleaning
83 figure(4);
84 subplot(1,2,1);
85 boxplot(BMI_raw, 'Labels', {'BMI (sebelum)'}); title('BMI Sebelum Cleaning'); grid on;
86 subplot(1,2,2);
```

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
86 boxplot(BMI_raw, 'Labels', {'BMI (sebelum)'}); title('BMI Sebelum Cleaning'); grid on;
87 subplot(1,2,2);
88 boxplot(BMI, 'Labels', {'BMI (sesudah)'}); title('BMI Sesudah Cleaning'); grid on;
89
90 %% -----
91 % STEP 6: REGRESI LINIER & PARABOLIK
92 %% -----
93 X = BMI;
94 Y = SBP;
95
96 % Model Linier: y = b1*x + b0
97 p1 = polyfit(X, Y, 1);
98 Y_pred1 = polyval(p1, X);
99
100 fprintf('\n=== Model Regresi Linier ===\n');
101 fprintf('y = %.4f*x + %.4f\n', p1(1), p1(2));
102
103 % Model Parabolik: y = c*x^2 + b*x + a
104 p2 = polyfit(X, Y, 2);
105 Y_pred2 = polyval(p2, X);
106
107 fprintf('\n=== Model Regresi Parabolik ===\n');
108 fprintf('y = %.4f*x^2 + %.4f*x + %.4f\n', p2(1), p2(2), p2(3));
```

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
107 fprintf('y = %.4f*x^2 + %.4f*x + %.4f\n', p2(1), p2(2), p2(3));
108
109 % Figure 5: Plot perbandingan model
110 X_plot = linspace(min(X), max(X), 300);
111 figure(5);
112 scatter(X, Y, 6, 'filled', 'MarkerFaceColor', '#4472C4', 'MarkerFaceAlpha', 0.1, 'DisplayName', 'Data Pasien');
113 hold on;
114 plot(X_plot, polyval(p1, X_plot), 'r-', 'LineWidth', 2.5, 'DisplayName', 'Regresi Linier');
115 plot(X_plot, polyval(p2, X_plot), 'g-', 'LineWidth', 2.5, 'DisplayName', 'Regresi Parabolik');
116 xlabel('BMI (kg/m²)'); ylabel('Tekanan Darah Sistolik (mmHg)');
117 title('Regresi Linier vs Parabolik: BMI vs SBP');
118 legend('Location', 'best'); grid on; hold off;
119
120 %% -----
121 % STEP 7: EVALUASI MODEL (R², RMSE, MAE) - tanpa function
122 %% -----
123 SS_tot = sum((Y - mean(Y)).^2);
124
125 SS_res1 = sum((Y - Y_pred1).^2);
126 R2_1 = 1 - SS_res1/SS_tot;
127 RMSE_1 = sqrt(mean((Y - Y_pred1).^2));
128 MAE_1 = mean(abs(Y - Y_pred1));
```

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
127 RMSE_1 = sqrt(mean((Y - Y_pred1).^2));
128 MAE_1 = mean(abs(Y - Y_pred1));
129
130 SS_res2 = sum((Y - Y_pred2).^2);
131 R2_2 = 1 - SS_res2/SS_tot;
132 RMSE_2 = sqrt(mean((Y - Y_pred2).^2));
133 MAE_2 = mean(abs(Y - Y_pred2));
134
135 fprintf('\n=== Evaluasi Model ===\n');
136 fprintf('%-12s R2 = %.4f | RMSE = %.4f | MAE = %.4f\n', 'Linier', R2_1, RMSE_1, MAE_1);
137 fprintf('%-12s R2 = %.4f | RMSE = %.4f | MAE = %.4f\n', 'Parabolik', R2_2, RMSE_2, MAE_2);
138
139 if R2_2 > R2_1
140     fprintf('>> Model PARABOLIK lebih baik (R2 lebih tinggi)\n');
141 else
142     fprintf('>> Model LINIER lebih baik (R2 lebih tinggi)\n');
143 end
144
145 % Figure 6: Residual Plot
146 res1 = Y - Y_pred1;
147 res2 = Y - Y_pred2;
148
149 figure(6);
```

Activate Windows
Go to Settings to activate Windows.

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
146 res1 = Y - Y_pred1;
147 res2 = Y - Y_pred2;
148
149 figure(6);
150 subplot(1,2,1);
151 scatter(Y_pred1, res1, 5, 'filled', 'MarkerFaceColor','r','MarkerFaceAlpha',0.1);
152 yline(0,'k--','LineWidth',1.5);
153 xlabel('Nilai Fitted'); ylabel('Residual');
154 title('Residual Plot - Linier'); grid on;
155
156 subplot(1,2,2);
157 scatter(Y_pred2, res2, 5, 'filled', 'MarkerFaceColor','b','MarkerFaceAlpha',0.1);
158 yline(0,'k--','LineWidth',1.5);
159 xlabel('Nilai Fitted'); ylabel('Residual');
160 title('Residual Plot - Parabolik'); grid on;
161
162 %% -----
163 % STEP 8: PREDIKSI DATA BARU
164 %% -----
165 BMI_test = [16.0, 18.5, 22.0, 25.0, 27.5, 30.0, 35.0, 40.0];
166 kategori = {'Sangat Kurus','Kurus','Normal','Normal Atas', ...
167             'Overweight','Obesitas I','Obesitas II','Obesitas III'};
```

Activate Windows
Go to Settings to activate Windows.

```
TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
168
169 fprintf('\n=== Prediksi SBP dari Model Parabolik ===\n');
170 fprintf('%-15s %-22s %-20s\n', 'BMI (kg/m2)', 'SBP Prediksi (mmHg)', 'Kategori BMI');
171 fprintf('%s\n', repmat('-',1,60));
172 for i = 1:length(BMI_test)
173     fprintf('%-15.1f %-22.2f %s\n', BMI_test(i), polyval(p2, BMI_test(i)), kategori{i});
174 end
175
176 % Figure 7: Plot prediksi
177 figure(7);
178 scatter(X, Y, 6, 'filled', 'MarkerFaceColor','r','MarkerFaceAlpha',0.1,'DisplayName','Data Pasien');
179 hold on;
180 plot(X_plot, polyval(p2, X_plot), 'g-', 'LineWidth', 2.5, 'DisplayName','Model Parabolik');
181 scatter(BMI_test, polyval(p2, BMI_test), 100, 'r^', 'filled', 'DisplayName','Titik Prediksi');
182 xlabel('BMI (kg/m²)'); ylabel('Tekanan Darah Sistolik (mmHg)');
183 title('Prediksi SBP Berdasarkan Model Parabolik');
184 legend('Location','best'); grid on; hold off;
185
186 %% -----
187 % STEP 9: PERHITUNGAN MANUAL REGRESI LINIER (Tabel Sigma)
188 %% -----
189 n = length(X);
```

Activate Windows
Go to Settings to activate Windows.

```

TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
187 % STEP 9: PERHITUNGAN MANUAL REGRESI LINIER (Tabel Sigma)
188 -----
189 n = length(X);
190 Sx = sum(X);
191 Sy = sum(Y);
192 Sx2 = sum(X.^2);
193 Sxy = sum(X.*Y);
194
195 fprintf('\n=== Perhitungan Manual Regresi Linier (Tabel Sigma) ===\n');
196 fprintf('n = %d\n', n);
197 fprintf('SigmaX = %.4f\n', Sx);
198 fprintf('SigmaY = %.4f\n', Sy);
199 fprintf('SigmaX2 = %.4f\n', Sx2);
200 fprintf('SigmaXY = %.4f\n', Sxy);
201
202 A = [n, Sx; Sx, Sx2];
203 B = [Sy; Sxy];
204 koef = A \ B;
205
206 fprintf('\nHasil Persamaan Normal:\n');
207 fprintf('b0 (intercept) = %.4f\n', koef(1));
208 fprintf('b1 (slope) = %.4f\n', koef(2));

```

```

TUBES MTKSD.m x tubes_mtksd_01.m x untitled x +
/MATLAB Drive/TUBES MTKSD.m
205
206 fprintf('\nHasil Persamaan Normal:\n');
207 fprintf('b0 (intercept) = %.4f\n', koef(1));
208 fprintf('b1 (slope) = %.4f\n', koef(2));
209 fprintf('\nVerifikasi vs polyfit:\n');
210 fprintf('polyfit -> b0 = %.4f | b1 = %.4f\n', p1(2), p1(1));
211 fprintf('(Kedua nilai identik = perhitungan benar)\n');
212
213 fprintf('\n===== \n');
214 fprintf('SEMUA LANGKAH SELESAI\n');
215 fprintf('===== \n');
216

```

5.2 Output Program

```

Command Window
=== Nama Kolom Dataset ===
{'id'} {'age'} {'gender'} {'height'} {'weight'} {'ap_hi'} {'ap_lo'} {'cholesterol'} {'gluc'} {'smoke'} {'alco'} {'active'} {'cardio'}

=== 5 Baris Pertama ===
   id   age  gender  height  weight  ap_hi  ap_lo  cholesterol  gluc  smoke  alco  active  cardio
   --   --  -
0     18393    2     168     62    130    80         1         1         0         0         1         0
1     20228    1     156     85    140    90         3         1         0         0         1         1
2     18857    1     165     64    150    70         5         1         0         0         0         1
3     17613    2     169     82    150   100         1         1         0         0         1         1
4     17474    1     156     56    100    60         1         1         0         0         0         0

Jumlah data asli: 70000 baris

--- Sebelum Cleaning ---
BRP | Min: 5.5 | Max: 208.7 | Mean: 27.6
SBP | Min: -150.0 | Max: 16020.0 | Mean: 128.8

--- Sesudah Cleaning ---
Data valid : 69731 baris
Data dihapus: 269 baris

```

Command Window

```
=== Statistik Deskriptif ===
Variabel      Min      Max      Mean      Median      Std
BMI           10.73    70.00    27.50     26.38      5.29
SBP           60.00    240.00   127.00    120.00     17.09

=== Model Regresi Linier ===
y = 0.8636*x + 103.2537

=== Model Regresi Parabolik ===
y = -0.0223*x^2 + 2.2403*x + 82.8668

=== Evaluasi Model ===
Linier        R2 = 0.0713 | RMSE = 16.4726 | MAE = 12.3988
Parabolik     R2 = 0.0760 | RMSE = 16.4311 | MAE = 12.3513
>> Model PARABOLIK lebih baik (R2 lebih tinggi)
```

Command Window

```
=== Prediksi SBP dari Model Parabolik ===
BMI (kg/m2)    SBP Prediksi (mmHg)    Kategori BMI
-----
16.0           113.01                 Sangat Kurus
18.5           116.69                 Kurus
22.0           121.37                 Normal
25.0           124.95                 Normal Atas
27.5           127.62                 Overweight
30.0           130.02                 Obesitas I
35.0           133.98                 Obesitas II
40.0           136.83                 Obesitas III

=== Perhitungan Manual Regresi Linier (Tabel Sigma) ===
n           = 69731
SigmaX      = 1917443.4807
SigmaY      = 8855826.0000
SigmaX2     = 54672974.3903
SigmaXY     = 245196951.8295


Hasil Persamaan Normal:
b0 (intercept) = 103.2537
b1 (slope)     = 0.8636
```

Command Window

```
Verifikasi vs polyfit:
polyfit -> b0 = 103.2537 | b1 = 0.8636
(Kedua nilai identik = perhitungan benar)
```

```
=====
SEMUA LANGKAH SELESAI
=====
```

5.3 Grafik Regresi



Scatter plot digunakan untuk melihat hubungan antara BMI dengan tekanan darah sistolik (SBP) pasien. Garis regresi linier menunjukkan adanya kecenderungan peningkatan SBP yang relatif konstan seiring bertambahnya BMI. Sementara itu, model parabolik memperlihatkan pola hubungan yang tidak sepenuhnya linear, di mana peningkatan SBP terlihat cukup jelas pada rentang BMI tertentu lalu mulai melandai pada BMI yang lebih tinggi. Dari bentuk kurva yang dihasilkan, model parabolik terlihat lebih mengikuti pola persebaran data sehingga dapat memberikan gambaran hubungan yang lebih fleksibel dibandingkan model linier.

BAB VI – EVALUASI MODEL


6.1 Hasil Evaluasi

Evaluasi model dilakukan menggunakan tiga metrik, yaitu **R² (Coefficient of Determination)**, **RMSE (Root Mean Square Error)**, dan **MAE (Mean Absolute Error)**. Nilai R² yang lebih tinggi menunjukkan kemampuan model yang lebih baik dalam menjelaskan variasi data, sedangkan nilai RMSE dan MAE yang lebih rendah menunjukkan tingkat kesalahan prediksi yang lebih kecil.

Model	R ²	RMSE	MAE
Regresi Linier	0,0713	16,4726	12,3988
Regresi Parabolik	0,0760	16,4311	12,3513

Berdasarkan hasil evaluasi, model parabolik memiliki nilai R² yang lebih tinggi serta nilai RMSE dan MAE yang lebih rendah dibandingkan model linier. Oleh karena itu, model parabolik dipilih sebagai model yang lebih baik untuk memprediksi tekanan darah sistolik berdasarkan BMI.

6.2 Residual Plot



Residual plot digunakan untuk melihat penyebaran error atau selisih antara nilai aktual dan nilai prediksi model. Residual yang baik seharusnya tersebar secara acak di sekitar garis nol tanpa membentuk pola tertentu.

Pada model linier maupun parabolik, titik-titik residual menyebar di sekitar garis nol. Namun, model parabolik menunjukkan penyebaran residual yang sedikit lebih baik dibandingkan model linier, yang sesuai dengan hasil evaluasi metrik sebelumnya. Hal ini menunjukkan bahwa model parabolik mampu mengikuti pola hubungan BMI dan tekanan darah sistolik dengan lebih baik.

6.3 Analisis Hasil

Berdasarkan hasil regresi, diperoleh persamaan model linier:

$$y = 0,8636x + 103,2537$$

dan persamaan model parabolik:

$$y = -0,0223x^2 + 2,2403x + 82,8668$$

Nilai R^2 model linier sebesar 0,0713 dan model parabolik sebesar 0,0760. Nilai tersebut menunjukkan bahwa BMI hanya mampu menjelaskan sekitar 7% variasi tekanan darah sistolik. Dengan kata lain, masih terdapat faktor-faktor lain yang memengaruhi tekanan darah sistolik, seperti usia, jenis kelamin, kadar kolesterol, kadar glukosa, kebiasaan merokok, dan aktivitas fisik.

Meskipun demikian, model parabolik tetap memberikan hasil yang lebih baik dibandingkan model linier karena memiliki nilai R^2 yang lebih tinggi serta nilai RMSE dan MAE yang lebih rendah. Oleh sebab itu, model parabolik dipilih sebagai model terbaik pada penelitian ini.

BAB VII – KESIMPULAN

7.1 Kesimpulan

Berdasarkan analisis data Cardiovascular Disease, diperoleh hubungan antara Body Mass Index (BMI) dan tekanan darah sistolik (SBP) menggunakan model regresi linier dan regresi parabolik. Setelah dilakukan proses data cleaning, jumlah data valid yang digunakan sebanyak 69.731 data.

Hasil evaluasi menunjukkan bahwa model parabolik memiliki performa yang lebih baik dibandingkan model linier dengan nilai R^2 sebesar 0,0760, RMSE sebesar 16,4311, dan MAE sebesar 12,3513. Oleh karena itu, model parabolik dipilih sebagai model terbaik untuk memprediksi tekanan darah sistolik berdasarkan nilai BMI.

Namun, nilai R^2 yang relatif rendah menunjukkan bahwa BMI bukan satu-satunya faktor yang mempengaruhi tekanan darah sistolik sehingga diperlukan variabel lain untuk meningkatkan akurasi model.

7.2 Saran

1. Menambahkan variabel lain seperti usia, jenis kelamin, kadar kolesterol, kadar glukosa, kebiasaan merokok, dan aktivitas fisik untuk meningkatkan kemampuan prediksi model.
2. Menggunakan metode pemodelan yang lebih kompleks seperti regresi multivariat atau machine learning.
3. Melakukan validasi model menggunakan data uji terpisah agar hasil evaluasi lebih akurat.
4. Menggunakan dataset yang lebih besar dan beragam untuk memperoleh hasil yang lebih representatif.
5. Melakukan penelitian lanjutan untuk mengetahui faktor-faktor yang paling berpengaruh terhadap tekanan darah sistolik.

DAFTAR PUSTAKA

- Sulianova. 2019. *Cardiovascular Disease Dataset*. Kaggle. Tautan: [Kaggle Cardiovascular](#), diakses pada 28 Mei 2026.
- MathWorks. 2026. *MATLAB Online*. Tautan: [MATLAB online](#), diakses pada 31 Mei 2026.
- Said, S. A., Hasanah, I., & Totong, J. 2026. Analisis pengaruh faktor lingkungan, genetik, dan gaya hidup terhadap risiko pengembangan penyakit kardiovaskular: Pendekatan regresi berganda dalam studi farmasi klinis.
- Wijayadhi, A., Effendi, M. M., & Rahardjo, S. B. (2023). Prediksi penyakit jantung dengan algoritma regresi linier. *Bulletin of Information Technology (BIT)*, 4(1), 15–28. <https://doi.org/10.47065/bit.v3i1.463>